

MCDI500

PROGRAMACIÓN PARA LA CIENCIA DE DATOS

EVALUACIÓN SUMATIVA 1

PATRONES TEMPORALES DE GENERACIÓN ELÉCTRICA EN CENTRALES TER CMPC

LAJA, PACÍFICO Y SANTA FE – ENERO A AGOSTO 2026

Nombre integrante/s:

- Verónica Durán Cisterna
- Raúl Moya Arriagada
- Daniela Rojas Vilches
- Manuel Sánchez Cárcamo

Curso:

MCDI500 - Programación para la ciencia de datos

Docente:

- Dr. Omar Salinas Silva

Fecha:

16 de septiembre de 2026

URL Proyecto: <https://github.com/vedurancisterna-alt/Grupo-2-Sumativa-1->

Índice General

Índice General	2
Índice de Tablas	3
Índice de Figuras.....	3
1. Introducción y contextualización	4
2. Definición de la problemática y objetivos	4
2.1 Pregunta de investigación	4
2.2 Objetivo general	4
2.3 Objetivos específicos	4
2.4 Alcance, restricciones y supuestos	5
3. Datos, alcance y variables	5
3.1 Condiciones de uso de los datos	6
4. Aplicación de herramientas científicas.....	6
5. Reproducibilidad técnica	6
6. Control de versiones y trazabilidad	6
7. Fase 1 - Definición del proyecto	7
8. Fase 2 - Preparación, transformación y validación	7
9. Validación técnica y evidencias	8
10. Vinculación con el mapa conceptual	8
11. Estado de avance F1-F4	10
12. Conclusiones.....	11
13. Bibliografía.....	12

Índice de Tablas

Tabla 1: Diccionario de variables, roles analíticos y uso en el dataset procesado.....	5
Tabla 2: Matriz de evidencias técnicas del proyecto disponibles en el repositorio GitHub.	8
Tabla 3. Matriz de vinculación entre los elementos del mapa conceptual y su evidencia técnica.....	10
Tabla 4. Resumen del estado de avance de las fases F1 a F4 del proyecto.	10

Índice de Figuras

Ilustración 1. Mapa conceptual actualizado del proyecto	9
---	---

1. Introducción y contextualización

El proyecto trabaja con datos públicos de generación real publicados por el Coordinador Eléctrico Nacional (CEN). El análisis se concentra en tres centrales -TER CMPC Laja, TER CMPC Pacífico y TER CMPC Santa Fe- y considera el período comprendido entre enero y agosto de 2026. A partir de estos registros se busca caracterizar cómo varía la generación eléctrica a lo largo del tiempo e identificar patrones relevantes en su comportamiento. La fuente oficial permite descargar los datos de generación real e incluye un diccionario asociado para interpretar sus variables (Coordinador Eléctrico Nacional, 2022). Además, el CEN señala que esta publicación responde al requisito legal establecido en la Ley 20.936, artículo 72-8 d) (Coordinador Eléctrico Nacional, 2026a).

La Sumativa 1 aborda las fases F1 y F2 del proyecto. En esta etapa se define el problema, se prepara el entorno de trabajo, se obtienen y exploran los datos y luego se aplican procesos de limpieza, transformación y validación. También se documentan las decisiones tomadas y se mantiene la trazabilidad del trabajo realizado. Las fases F3 y F4 quedan destinadas al desarrollo del núcleo algorítmico, análisis de eficiencia e implementación orientada a objetos, para continuar posteriormente con la integración y comunicación de los resultados.

El volumen y la estructura horaria de los registros hacen necesario utilizar programación para transformar, validar y analizar los datos de manera reproducible.

2. Definición de la problemática y objetivos

2.1 Pregunta de investigación

¿Qué patrones temporales de generación eléctrica caracterizan a las centrales TER CMPC Laja, TER CMPC Pacífico y TER CMPC Santa Fe durante el período enero-agosto de 2026?

La pregunta se formuló con un alcance deliberadamente acotado. Busca responder solo aquello que puede observarse y analizarse a partir de las variables disponibles en el conjunto de datos, evitando extender el estudio hacia aspectos que la fuente no permite sustentar. Este enfoque sigue el criterio de pregunta analizable definido para la Fase 1 del proyecto (Salinas Silva, 2026).

2.2 Objetivo general

Caracterizar los patrones temporales de generación eléctrica de las centrales TER CMPC Laja, TER CMPC Pacífico y TER CMPC Santa Fe durante enero-agosto de 2026, utilizando datos públicos del Coordinador Eléctrico Nacional mediante un proceso reproducible de preparación, validación y análisis.

2.3 Objetivos específicos

- Caracterizar la distribución horaria, diaria y mensual de la generación eléctrica de las tres centrales.
- Comparar los patrones temporales observados entre TER CMPC Laja, TER CMPC Pacífico y TER CMPC Santa Fe.
- Analizar la frecuencia y la distribución temporal de los registros con generación igual a 0 MWh, sin atribuirles causas operacionales que no estén respaldadas por la fuente.
- Identificar regularidades y diferencias que sirvan de base para las fases posteriores de análisis, modelación y comunicación.

2.4 Alcance, restricciones y supuestos

- El proyecto se limita al análisis de la generación eléctrica registrada para las centrales TER CMPC Laja, TER CMPC Pacífico y TER CMPC Santa Fe durante el período enero-agosto de 2026. El trabajo utiliza exclusivamente datos públicos de Generación Real del Coordinador Eléctrico Nacional y se concentra en caracterizar patrones temporales a nivel horario, diario y mensual.
- El análisis queda restringido por la información disponible en la fuente. Por esta razón, no se atribuyen causas operacionales, económicas o de mantenimiento a los comportamientos observados cuando estas no pueden ser verificadas con los datos disponibles. Del mismo modo, se mantiene la codificación horaria 1-24 informada por el CEN, sin asignar equivalencias adicionales que no estén documentadas.
- Como supuesto de trabajo, se considera que los registros publicados por el CEN corresponden a mediciones válidas mientras no exista evidencia suficiente para clasificarlos como errores. Bajo este criterio, los valores iguales a 0 MWh se conservan y se analizan de forma descriptiva. También se asume como estructura esperada la presencia de 24 observaciones por cada combinación central-fecha, condición que posteriormente se verifica durante la Fase 2.

3. Datos, alcance y variables

El archivo original descargado desde la plataforma de Generación Real del CEN contiene 359.891 filas y 33 columnas. Para esta etapa del proyecto, el análisis se acotó a las centrales TER CMPC Laja, TER CMPC Pacífico y TER CMPC Santa Fe, considerando el período entre el 1 de enero y el 31 de agosto de 2026. Después de aplicar estos filtros se obtuvieron 729 registros en formato ancho: 243 días para cada una de las tres centrales.

En la fuente original, cada hora del día aparece en una columna distinta, desde Hora 1 hasta Hora 24. Esta estructura resulta poco práctica para trabajar series temporales, por lo que los datos se reorganizaron desde formato ancho a formato largo. El dataset resultante contiene 17.496 filas y 13 columnas. Cada fila representa una combinación de central, fecha y hora. Se mantuvo la codificación horaria 1-24 utilizada por el CEN, sin asignarle una equivalencia horaria distinta que no esté documentada por la fuente.

La Tabla N°1 muestra la clasificación de las variables contenidas en el dataset, definiendo su rol analítico o tipo y función dentro del estudio.

Variable	Rol	Uso
Generacion_MWh	Cuantitativa continua	Variable de respuesta principal
Hora	Cuantitativa discreta	Patrón intradiario
Fecha	Temporal	Ordenamiento y agregación temporal
Central	Categoría nominal	Comparación entre centrales
Día_Semana	Categoría nominal (cíclica)	Patrones semanales
ID_Observacion	Identificador	Unicidad y trazabilidad

Tabla 1: Diccionario de variables, roles analíticos y uso en el dataset procesado.

Dentro del conjunto seleccionado, las variables Coordinado, Tipo y Subtipo mantienen el mismo valor en todos los registros. Se conservaron porque entregan contexto sobre los datos, aunque no permiten diferenciar las observaciones utilizadas en este análisis.

3.1 Condiciones de uso de los datos

Los datos utilizados provienen de la plataforma pública de Generación Real del Coordinador Eléctrico Nacional (CEN). De acuerdo con los Términos y Condiciones de Uso de su sitio web, esta información puede descargarse para fines personales y/o académicos, siempre que se identifique y cite la fuente. En este proyecto se utiliza bajo esas condiciones y se mantiene explícitamente su procedencia (Coordinador Eléctrico Nacional, 2026b).

4. Aplicación de herramientas científicas

El proyecto se desarrolla en Python utilizando Jupyter Notebook como entorno de trabajo. Pandas se usa para cargar, filtrar, transformar y validar los datos; NumPy apoya las operaciones numéricas y Matplotlib se emplea para generar visualizaciones. La implementación del pipeline se apoya tanto en documentación técnica oficial como en bibliografía especializada sobre análisis de datos con Python (Python Software Foundation, 2026; pandas development team, 2026; NumPy Developers, 2026; McKinney, 2022).

La lógica que puede reutilizarse se separó de los notebooks y se organizó en módulos dentro de src/: carga.py, transformacion.py y validacion.py. Con esta estructura se evita repetir código, se facilita el mantenimiento y las funciones pueden probarse de forma independiente antes de incorporarlas al flujo completo.

5. Reproducibilidad técnica

El proyecto utiliza un entorno virtual .venv con Python 3.14.3 y un archivo requirements.txt para registrar las dependencias necesarias. Entre las principales librerías utilizadas se encuentran pandas 3.0.5, NumPy 2.5.3 y Matplotlib 3.11.1. Los notebooks F1 y F2 se comprobaron mediante Restart Kernel -> Run All, ejecutando todo el flujo desde un kernel reiniciado. De esta manera, la reproducibilidad se verifica desde la configuración del entorno y la instalación de dependencias hasta la obtención de resultados que pueden volver a comprobarse.

El repositorio se organiza en las carpetas F1/, F2/, data/raw/, data/processed/, docs/, docs/evidencias/ y src/. A esta estructura se suman archivos de apoyo técnico como README.md, requirements.txt y .gitignore.

6. Control de versiones y trazabilidad

Git se utiliza para el control local de versiones y GitHub como repositorio remoto de trabajo colaborativo. Esta separación permite distinguir el mecanismo de versionamiento del servicio utilizado para almacenar, compartir y coordinar los avances del proyecto, tal como se plantea en la guía de Git y GitHub de la asignatura (Magíster en Ciencia de Datos e Inteligencia Artificial, 2026).

Los commits registran cambios concretos realizados durante el desarrollo: correcciones en F1 y F2, modularización del código, incorporación del diccionario del CEN, eliminación de un dataset obsoleto, actualización del README y renovación de evidencias.

El historial del repositorio permite identificar contribuciones de los cuatro integrantes del equipo mediante commits asociados a documentación, carga y actualización de datasets, definición del proyecto, preparación de datos, evidencias y ajustes del repositorio.

Reproducibilidad y trazabilidad cumplen funciones distintas. La primera permite volver a ejecutar el proyecto bajo condiciones documentadas. La segunda permite reconstruir qué cambió, cuándo ocurrió y cómo cada modificación se relaciona con el código, la documentación y las evidencias generadas.

7. Fase 1 - Definición del proyecto

F1_definicion.ipynb reúne la definición inicial del proyecto. Allí se establece la pregunta de investigación, los objetivos, el alcance, la fuente de datos, la unidad de observación, los roles de las variables, los supuestos y las principales decisiones metodológicas.

El notebook también documenta el entorno técnico y la relación entre reproducibilidad y trazabilidad. Además, incorpora celdas ejecutables para localizar la raíz del proyecto, cargar la fuente de datos y realizar verificaciones iniciales. Así, F1 no queda limitado a una descripción conceptual: también establece el punto de partida técnico desde el cual se ejecuta el resto del trabajo.

8. Fase 2 - Preparación, transformación y validación

F2_preparacion_datos.ipynb desarrolla el flujo de preparación de los datos. Incluye la carga y exploración inicial, el filtrado de las centrales y fechas seleccionadas, la transformación desde formato ancho a largo, la creación de variables derivadas, las validaciones y la exportación del dataset procesado. Después de la transformación se mantienen 24 observaciones por cada combinación central-fecha, condición que se comprueba mediante código.

El dataset final contiene 17.496 observaciones y 13 variables. Las validaciones muestran 0 valores nulos, 0 duplicados exactos, 0 identificadores duplicados y 0 valores negativos en Generacion_MWh. El conjunto incluye 3 centrales y 243 fechas. No se aplicó imputación, porque no existen valores nulos en el resultado, ni normalización, ya que en esta etapa interesa conservar la escala original de generación para el análisis descriptivo.

También se identificaron 4.438 observaciones con generación igual a 0 MWh, equivalentes al 25,37 % del dataset final. La proporción varía entre centrales: 54,75 % en TER CMPC Laja, 6,36 % en TER CMPC Pacífico y 14,99 % en TER CMPC Santa Fe. Estos registros se mantienen en el conjunto de datos y no se clasifican automáticamente como fallas, detenciones o mantenciones, porque la fuente disponible no entrega antecedentes suficientes para atribuirles una causa operacional.

9. Validación técnica y evidencias

La lógica de validación se concentra en `src/validacion.py`. Este módulo comprueba dimensiones, valores nulos, duplicados, unicidad del identificador, presencia de valores negativos, número de centrales y existencia de exactamente 24 observaciones por cada combinación central-fecha.

Las pruebas consideran tres escenarios distintos. El caso normal verifica el funcionamiento esperado del flujo. El caso límite introduce de manera artificial un registro duplicado para comprobar que la validación lo detecte. Finalmente, el caso de excepción utiliza una ruta de archivo inexistente para verificar que el sistema controle correctamente ese tipo de error.

Evidencia	Propósito
01_F1_pregunta_objetivos.png	Pregunta de investigación y objetivos
02_F1_ejecucion_reproducible.png	Ejecución técnica de F1
03_F2_validacion_final.png	Validación integral del dataset final
04_F2_pruebas_tecnicas.png	Casos normal, límite y excepción
05_F2_analisis_ceros.png	Caracterización de registros 0 MWh
06_git_historial_commits.png	Trazabilidad mediante Git/GitHub
07_estructura_repositorio.png	Organización y modularización

Tabla 2: Matriz de evidencias técnicas del proyecto disponibles en el repositorio GitHub.

Cada evidencia se encuentra identificada en la Tabla N°2 con el mismo nombre utilizado en el repositorio, lo que permite relacionar directamente el contenido del informe con los archivos de respaldo.

10. Vinculación con el mapa conceptual

El mapa conceptual parte de la pregunta de investigación y organiza los principales componentes del proyecto: problema y datos, variables, ciclo de vida, ecosistema tecnológico, entorno técnico, documentación científica, reproducibilidad, trazabilidad, supuestos y fases de trabajo. Los elementos correspondientes a F1 y F2 reflejan lo que ya fue implementado, mientras que F3 y F4 se presentan como etapas proyectadas para continuar el análisis y comunicar los resultados.

Legenda Explicativa del Mapa Conceptual




Ilustración 1. Mapa conceptual actualizado del proyecto

Elemento	Tipo	Estado	Evidencia
Pregunta de investigación	Investigativo	Materializado	F1/F1_definicion.ipynb
Fuente y delimitación CEN	Datos	Materializado	F1 y F2; README.md
Transformación ancho - > largo	Pipeline	Materializado	src/transformacion.py; F2
Validación integral	Control técnico	Materializado	src/validacion.py; evidencia 03
Pruebas normal/límite/excepción	Pruebas	Materializado	F2; evidencia 04
Reproducibilidad	Gobierno técnico	Materializado	requirements.txt; notebooks
Trazabilidad	Gobierno técnico	Materializado	Git/GitHub; evidencia 06
Núcleo algorítmico y eficiencia	F3	Proyectado	Trabajo posterior
Comunicación de resultados	F4	Proyectado	Trabajo posterior

Tabla 3. Matriz de vinculación entre los elementos del mapa conceptual y su evidencia técnica.

La Tabla N°3 permite comprobar en ambos sentidos la relación entre el mapa conceptual y lo que efectivamente se implementó. Cada componente desarrollado cuenta con una evidencia concreta, ya sea en un notebook, un módulo, un archivo de apoyo técnico o una captura. Los elementos correspondientes a F3 y F4 se mantienen separados, de modo que el informe no presente como realizado aquello que todavía pertenece a etapas posteriores.

11. Estado de avance F1-F4

Fase	Estado	Contenido
F1	Materializado	Pregunta, objetivos, alcance, variables, entorno y definición reproducible.
F2	Materializado	Carga, exploración, limpieza, transformación, validación, pruebas y evidencias.
F3	Proyectado	Desarrollo del núcleo algorítmico, análisis de eficiencia e implementación orientada a objetos, incorporando el análisis de los patrones temporales identificados
F4	Proyectado	Integración de resultados, visualización, discusión, conclusiones y comunicación final del proyecto.

Tabla 4. Resumen del estado de avance de las fases F1 a F4 del proyecto.

12. Conclusiones

La Sumativa 1 permitió dejar una base técnica reproducible y trazable para estudiar los patrones temporales de generación eléctrica de las tres centrales seleccionadas. El proceso desde la fuente completa, con 359.891 filas y 33 columnas, hasta un dataset analítico de 17.496 filas y 13 variables quedó documentado, modularizado y validado.

Con ello, se obtuvo un conjunto de datos consistente, con una unidad de observación bien definida y controles explícitos sobre la calidad de los datos.

También quedó delimitado con claridad qué parte del proyecto corresponde al trabajo ya realizado y qué nos queda pendiente. Las fases F1 y F2 se encuentran implementadas, mientras que F3 y F4 se proyectan para el desarrollo algorítmico, análisis de eficiencia, implementación orientada a objetos y posterior integración y comunicación de resultados..

Buscamos mantener la coherencia entre la pregunta de investigación planteada, el estado actual de nuestro repositorio y los próximos pasos del proyecto.

Un resultado relevante fue la identificación de registros con generación igual a 0 MWh. Mantuvimos estos valores y los analizamos de forma descriptiva, sin atribuirles causas operacionales, principalmente porque la fuente no permite demostrar esas causas. Esta decisión mantiene el análisis dentro de los límites de la evidencia con que contamos y evita introducir interpretaciones no verificables.

13. Bibliografía

Coordinador Eléctrico Nacional. (2022). *Diccionario de datos para la descarga de datos Portal Web Sistema de Información Pública (SIP)*, B43-DIN-04. <https://www.coordinador.cl/wp-content/uploads/2022/11/B43-DIN-04-Diccionario-de-Datos-Web-SIP.pdf>

Coordinador Eléctrico Nacional. (2026a). *Generación real*. Portal de Operación Real del Sistema Eléctrico Nacional. <https://www.coordinador.cl/operacion/graficos/operacion-real/generacion-real/>

Coordinador Eléctrico Nacional. (2026b). *Términos y condiciones de uso*. <https://www.coordinador.cl/terminos-y-condiciones/>

Magíster en Ciencia de Datos e Inteligencia Artificial. (2026). *Guía de Git y GitHub: Control de versiones y reproducibilidad en el ecosistema científico de Python. Versión para Windows*. Facultad de Ingeniería, Universidad Andrés Bello. https://github.com/magistercienciadatos/Material_Didactico_Semana1/blob/main/3_Gu%C3%A1%20de%20Git_Github/MCDI500_Gu%C3%A1%20de%20Git_Github_Windows.pdf

McKinney, W. (2022). *Python for data analysis: Data wrangling with pandas, NumPy, and Jupyter* (3rd ed.). O'Reilly Media. <https://www.oreilly.com/library/view/python-for-data/9781098104023/>

NumPy Developers. (2026). *NumPy documentation*. <https://numpy.org/doc/>

pandas development team. (2026). *pandas documentation*. <https://pandas.pydata.org/docs/>

Python Software Foundation. (2026). *Python 3 documentation*. <https://docs.python.org/3/>

Salinas Silva, O. (2026). *Programación para la ciencia de datos* [Presentación de clase, Semana 1]. Magíster en Ciencia de Datos e Inteligencia Artificial, Universidad Andrés Bello. https://github.com/magistercienciadatos/Material_Didactico_Semana1/blob/main/1_Presentaci%C3%B3n_Semana1/MCDI500_Semana_1_depurada_con_guion.pptx